

GEODETECTOR: un pipeline híbrido basado en inteligencia artificial para la detección, clasificación y geolocalización automatizada de letreros turísticos en rutas y carreteras

Felipe Córdova
Instituto de Informática
Universidad Austral de Chile
Valdivia, Chile
felipe.cordova@alumnos.uach.cl

Luis Veas-Castillo
Instituto de Informática
Universidad Austral de Chile
Valdivia, Chile
luis.veasc@inf.uach.cl

Christian Lazo
Instituto de Informática
Universidad Austral de Chile
Valdivia, Chile
clazo@inf.uach.cl

Resumen—La información disponible en letreros turísticos instalados en rutas rurales y carreteras permanece escasamente integrada a sistemas digitales de inventario territorial. Este artículo presenta GEODETECTOR, un pipeline híbrido que combina detección de letreros, sincronización GPS, extracción de regiones de interés, reconocimiento óptico de caracteres, clasificación semántica por taxonomía turística y visualización de resultados georreferenciada. La propuesta fue evaluada con videos capturados desde un vehículo en movimiento en tres rutas de la Región de Los Lagos, Chile, bajo condiciones reales de iluminación, clima y velocidad. El modelo fue entrenado mediante transfer learning sobre un dataset propio de 2.000 imágenes etiquetadas de letreros capturados principalmente en Chile y Argentina, publicado en IEEE DataPort. La evaluación experimental consideró cuatro configuraciones de captura, combinando dos resoluciones (1080p y 720p) y dos tasas de frames (30 FPS y 15 FPS), donde el modelo alcanzó Precisión entre 0,77 y 0,91, Recall entre 0,50 y 0,74 y F1-score entre 0,61 y 0,76, mientras que el reconocimiento de texto obtuvo un Character Error Rate entre 0,08 y 0,27. La evaluación end-to-end mostró que el pipeline completó automáticamente la detección, lectura, clasificación y georreferenciación del 57,1 % de los letreros turísticos correctamente detectados en la configuración original de captura. Los resultados evidencian la viabilidad de utilizar visión artificial para apoyar el inventario de infraestructura turística vial en entornos no controlados.

Index Terms—visión artificial, YOLO, transfer learning, OCR, georreferenciación, letreros turísticos, inteligencia artificial, rutas rurales.

I. INTRODUCCIÓN

Las rutas y carreteras rurales concentran una cantidad relevante de información territorial que no siempre se encuentra disponible en plataformas digitales. En particular, muchos emprendimientos turísticos, servicios de alimentación, alojamientos y actividades recreativas se anuncian mediante letreros instalados al borde del camino. Estos elementos cumplen una función informativa para los viajeros, pero también constituyen una fuente de datos potencialmente valiosa para municipios, organismos de turismo y planificadores territoriales. Sin embargo,

su registro suele depender de levantamientos manuales, costosos y difíciles de actualizar.

Los avances recientes en detección de objetos y reconocimiento de texto en escenas naturales permiten abordar este problema desde una perspectiva automatizada. Modelos de detección como YOLO han demostrado alta eficiencia en escenarios viales y aplicaciones de transporte inteligente [1], [2]. Asimismo, los sistemas de reconocimiento óptico de caracteres (OCR) y Scene Text Recognition (STR) han ampliado la capacidad de extraer texto desde imágenes complejas [3], [4]. No obstante, la señalética turística rural presenta dificultades particulares: variabilidad visual, tipografías no estandarizadas, materiales artesanales, deterioro físico, bajo contraste, vegetación que obstruye parcialmente los letreros, condiciones climáticas variables, y condiciones externas al objeto de interés como la velocidad del vehículo, la presencia de suciedad en el parabrisas o las limitaciones propias de la cámara de un smartphone durante la captura.

La literatura sobre señales de tránsito se concentra principalmente en señalética regulada, con colores, formas y diseños normalizados [5], [6]. En cambio, los letreros turísticos rurales y comerciales no estandarizados han sido escasamente estudiados, especialmente en contextos latinoamericanos. Además, la detección visual por sí sola no entrega la posición geográfica real del objeto, por lo que es necesario sincronizar el video con datos de geolocalización [7]. Esta integración entre visión artificial, OCR, clasificación semántica y georreferenciación constituye el foco de este trabajo.

Este artículo presenta GEODETECTOR, un pipeline híbrido orientado a detectar, interpretar y geolocalizar letreros turísticos capturados desde vehículos en movimiento. La propuesta se valida mediante videos reales adquiridos en rutas de la Región de Los Lagos, Chile, considerando distintas resoluciones, tasas de frames por segundo y condiciones climáticas. Las principales contribuciones son: (i) la construcción de un dataset propio de 2.000 imágenes etiquetadas de letreros rurales, urbanos y turísticos, publicado en IEEE DataPort; (ii)

el diseño de un pipeline end-to-end que integra detección, OCR, clasificación semántica y geolocalización; y (iii) la evaluación experimental en condiciones reales, incluyendo una medición integral que muestra que el pipeline logra completar automáticamente el flujo para el 57,1 % de los letreros turísticos correctamente detectados.

II. TRABAJOS RELACIONADOS

La detección de objetos en video ha evolucionado de manera significativa gracias a modelos profundos de una y dos etapas. Faster R-CNN prioriza precisión mediante propuestas de región [8], mientras que la familia YOLO privilegia velocidad de inferencia y ha sido ampliamente adoptada en aplicaciones vehiculares [2], [9]. Sin embargo, distintos trabajos han reportado degradación de desempeño ante lluvia, niebla, baja iluminación y ruido visual [10]. Estos factores son especialmente relevantes cuando los objetos aparecen durante pocos segundos y a distancias variables.

En reconocimiento de texto, el OCR tradicional ha sido utilizado en dominios como banca, compras en línea y salud [11]–[13]. En escenas naturales, el problema es más complejo debido a fondos no uniformes, perspectivas, rotaciones, tipografías diversas y oclusiones. Los enfoques STR han mejorado la lectura de texto irregular, pero muchos benchmarks se concentran en señalética urbana o texto en inglés, sin representar adecuadamente letreros artesanales de rutas rurales latinoamericanas [4], [14].

Los datasets de señales de tránsito, como TT-100K (Tsinghua-Tencent 100K) y GTSDb (German Traffic Sign Detection Benchmark), han permitido avances importantes en detección de señalética regulada [5], [6]. No obstante, sus clases y distribuciones visuales difieren del dominio turístico rural, donde predominan letreros informales, materiales heterogéneos y ausencia de estándares gráficos. Esta diferencia produce un problema de cambio de dominio o *domain shift*, frente al cual el transfer learning es una alternativa efectiva cuando se dispone de datos específicos limitados [15]–[17]. GEODETECTOR aborda esta brecha mediante un dataset propio y un pipeline integrado que combina visión, texto y geolocalización.

III. METODOLOGÍA

III-A. Visión general del pipeline

GEODETECTOR se organiza en dos etapas, como se muestra en la Figura 1. La **Etap 1** construye el modelo de detección mediante un dataset etiquetado, su división en entrenamiento, validación y prueba, y el fine-tuning de un modelo YOLO11m. La **Etap 2** implementa el modelo en un escenario de captura vehicular: se procesa el video, se sincroniza con la traza GPS, se extraen regiones de interés (ROI), se aplica OCR, se clasifica semánticamente el contenido textual y se visualizan los resultados en un mapa.

III-B. Construcción del dataset

El dataset fue construido a partir de recorridos realizados entre enero y septiembre de 2025 en cinco regiones de

Tabla I
DISTRIBUCIÓN GEOGRÁFICA DE LAS IMÁGENES RECOLECTADAS.

Región	Localidades principales	Cantidad
La Araucanía	Pucón, Villarrica, Caburgua, Licanray, Loncoche	979
Los Lagos	Puerto Montt, Frutillar, Calbuco, Puerto Varas	542
Los Ríos	Valdivia, Panguipulli, Lago Ranco, Lanco	467
O'Higgins	Quinta de Tilcoco, Rancagua	7
El Maule	Colbún, San Clemente	2
Argentina	San Carlos de Bariloche	3

Chile y una localidad de Argentina. Las imágenes fueron capturadas con un smartphone Samsung Galaxy S23 en contextos urbanos, rurales y turísticos, considerando variabilidad de distancia, ángulo, iluminación, materialidad y estado de conservación de los letreros. Cada imagen fue etiquetada manualmente mediante Label Studio [18], encerrando cada letrero visible con un bounding box que delimita su área exacta, usando una clase única: *signboard* (letrero). Las etiquetas fueron exportadas en formato TXT estándar de YOLO, donde cada archivo contiene una línea por letrero presente en la imagen, con el formato `class x_center y_center width height`, siendo todos los valores normalizados entre 0 y 1 respecto a las dimensiones de la imagen, y la metadata se consolidó mediante scripts en Python [19]. Para resguardar privacidad, se difuminaron rostros, patentes de vehículos, códigos QR y números telefónicos visibles mediante GIMP [20]. El dataset está publicado en IEEE DataPort [21]. La Tabla I resume la distribución geográfica del dataset, incluyendo las regiones, las localidades principales y la cantidad de imágenes recolectadas por zona.

III-C. Modelo de detección

Se utilizó YOLO11m como modelo base, seleccionando la variante *medium* por su equilibrio entre capacidad de representación y generalización para el tamaño del dataset. Se aplicó transfer learning a partir de pesos preentrenados y fine-tuning sobre el dataset propio. Las imágenes de entrada fueron configuradas a 640×640 píxeles, tamaño al que YOLO redimensiona internamente mediante *letterboxing* [22], preservando la relación de aspecto de las imágenes originales del dataset que presentan dimensiones superiores [23]. El entrenamiento se realizó con 50 épocas y parada temprana con paciencia de 5 épocas. La división de datos fue 70 % entrenamiento, 15 % validación y 15 % prueba, resultando en 1.400, 300 y 300 imágenes respectivamente. La Tabla II resume el desempeño final del detector en validación, evitando incluir curvas de entrenamiento para ajustarse al límite de extensión del presente artículo. **Este proceso de entrenamiento se ejecuta en el supercomputador Patagón de la Universidad Austral de Chile [24], y tuvo un tiempo de cómputo de 23 minutos con 28 segundos (0.391 horas) utilizando una GPU NVIDIA L40.**




Figura 1. Pipeline general de GEODETECTOR. La Etapa 1 construye y valida el modelo de detección; la Etapa 2 integra captura, sincronización GPS, OCR, clasificación semántica y visualización georreferenciada.

Tabla II
MÉTRICAS RESUMIDAS DEL MODELO YOLO11M PERSONALIZADO.

Métrica	Valor
Precisión	0,88
Recall	0,83
mAP@50	0,92
mAP@50:95	0,74



Figura 2. Ejemplos de detecciones realizadas por el modelo YOLO11m personalizado sobre letreros con distinta apariencia visual.

La Figura 2 muestra ejemplos de detecciones obtenidas sobre imágenes del conjunto de prueba. Estas detecciones permiten observar la respuesta del modelo ante diversidad de formas, materiales, distancias y condiciones de iluminación.

III-D. OCR, taxonomía y geolocalización

Una vez seleccionada la detección de mayor confianza para cada letrero mediante el tracking por apariencia implementado en la Etapa 2 de Implementación del Modelo de Detección de Letreros, esta se recorta como ROI y se procesa mediante transformación a escala de grises y thresholding, técnica utilizada para mejorar el contraste previo al OCR [25]. Dicho tracking opera sobre un fotograma por segundo del video, igual que los fotogramas enviados al modelo de detección, y asocia las detecciones de un mismo letrero mediante comparación de histogramas de color en el espacio HSV [26], [27]. El reconocimiento de texto se realiza con PaddleOCR [28], [29], reteniendo resultados con confianza superior a 0,5. Luego, el texto se normaliza y se compara contra una taxonomía de palabras clave basada en servicios turísticos definidos por el Servicio Nacional del Turismo de Chile [30], complementada con términos identificados durante la recolección de datos en terreno. La comparación usa coincidencia exacta y similitud difusa para tolerar errores de OCR [31]. La Tabla III resume la taxonomía utilizada.

La geolocalización se obtiene sincronizando temporalmente el video con una traza GPX registrada mediante GeoTracker [32]. Se extrae la hora de finalización y duración del video con pymediainfo [33]; luego se calcula la hora de inicio como

Tabla III
TAXONOMÍA DE CLASIFICACIÓN SEMÁNTICA DE LETREROS TURÍSTICOS.

Categoría	Palabras clave	Ejemplos
Alojamiento	17	cabaña, hostel, hotel, hospedaje, apart hotel
Alimentación	73	restaurant, picada, almuerzos, mini-market, comida casera
Recreativa	56	rafting, cabalgatas, trekking, playa, artesanías
Otros	–	venta de terrenos, talleres, tránsito u otra señalética no turística

$t_{inicio} = t_{fin} - D$, donde D es la duración en segundos. La traza GPS se filtra a un punto por segundo para asociar cada frame procesado con su coordenada geográfica. Los resultados se consolidan con Pandas [34] y se visualizan en un sistema de información geográfica (SIG).

IV. CONFIGURACIÓN EXPERIMENTAL

El pipeline fue ejecutado en el supercomputador Patagón de la Universidad Austral de Chile [24]. Para entrenamiento, inferencia y OCR se utilizaron recursos GPU, principalmente NVIDIA L40, mientras que tareas de sincronización y consolidación fueron ejecutadas con menor demanda computacional. El desarrollo se realizó en Python, empleando Ultralytics, PaddleOCR, OpenCV [35], Pandas y herramientas auxiliares como FFmpeg para generar variantes de resolución y FPS [36].

La evaluación utilizó tres videos reales capturados desde un vehículo a velocidades entre 50 y 70 km/h. Cada video original fue grabado en 1080p a 30 FPS y transformado en tres variantes: 1080p a 15 FPS, 720p a 30 FPS y 720p a 15 FPS. En total, se evaluaron 12 escenarios. La Tabla IV resume las condiciones de captura. LR corresponde al total de letreros reales observados y LRT a los letreros reales turísticos según la taxonomía.

Para la tarea de detección se calcularon las métricas de Precisión, Recall y F1-score a partir de los verdaderos positivos (TP), falsos positivos (FP) y falsos negativos (FN), utilizando como ground truth un conteo manual frame a frame realizado por el autor [37], sobre la base de la taxonomía presentada en la Tabla III. Para evitar el conteo múltiple de un mismo letrero detectado en frames consecutivos, se realizó un seguimiento visual manual de cada letrero de forma individual a lo largo del video, asociando todas sus detecciones a una única instancia para efectos de la evaluación. Estas métricas se definen según las ecuaciones 1, 2 y 3:

Tabla IV
ESCENARIOS EXPERIMENTALES EVALUADOS.

Video	Sector	Hora	Duración	Periodo	Clima	Velocidad	LR	LRT	Configuraciones
V1	Carretera Austral	11:13	4:03 min	Mañana	Lluvia	50–70 km/h	87	23	1080p/720p; 30/15 FPS
V2	Río Maullín	10:17	4:13 min	Mañana	Neblina	50–70 km/h	34	4	1080p/720p; 30/15 FPS
V3	Camino a Ensenada	16:52	5:58 min	Tarde	Despejado	50–70 km/h	91	19	1080p/720p; 30/15 FPS

Tabla V
INTERPRETACIÓN DE LOS VALORES DE CER UTILIZADOS COMO REFERENCIA.

Rango de CER	Interpretación	Descripción
$CER = 0$	Perfecto (P)	Reconocimiento perfecto, sin errores de OCR.
$0 < CER \leq 0,05$	Excelente (E)	Desempeño excelente, con muy pocos errores de reconocimiento.
$0,05 < CER \leq 0,10$	Bueno (B)	Desempeño bueno y suficiente para la mayoría de aplicaciones prácticas.
$0,10 < CER \leq 0,20$	Aceptable (A)	Desempeño aceptable, aunque con errores perceptibles en el texto reconocido.
$CER > 0,20$	Deficiente (D)	Desempeño deficiente, con una alta cantidad de errores de OCR.

$$\text{Precisión} = \frac{TP}{TP + FP} \quad (1)$$

$$\text{Recall} = \frac{TP}{TP + FN} \quad (2)$$

$$F1\text{-score} = 2 \cdot \frac{\text{Precisión} \cdot \text{Recall}}{\text{Precisión} + \text{Recall}} \quad (3)$$

Para evaluar el desempeño del reconocimiento óptico de caracteres (OCR) se utilizó Character Error Rate (CER), calculado a partir de la distancia de edición de Levenshtein [38], [39] entre el texto reconocido por el modelo y el texto de referencia. Este texto de referencia se obtuvo mediante una transcripción manual del contenido textual de cada letrero identificado en el ground truth de detección, la cual fue comparada con la salida del OCR utilizando el algoritmo de Levenshtein, según se define en la ecuación 4:

$$CER = \frac{S + D + I}{N} \quad (4)$$

donde S , D e I corresponden al número de sustituciones, eliminaciones e inserciones de caracteres necesarias para transformar el texto reconocido en el texto de referencia, y N es el número total de caracteres del texto de referencia.

Para la interpretación de los resultados se definen rangos de referencia adaptados del estándar utilizado en plataformas de reconocimiento de texto [39]. La Tabla V resume las categorías de interpretación utilizadas según el valor de CER obtenido.

V. RESULTADOS

V-A. Detección y OCR

La Tabla VI resume el desempeño por video y configuración. La Precisión se mantiene relativamente estable entre 0,77 y 0,91, lo que indica que el modelo controla razonablemente los falsos positivos en condiciones reales. El Recall presenta mayor variabilidad, entre 0,50 y 0,74, reflejando la dificultad de detectar letreros que aparecen brevemente en escena o bajo degradación visual. El F1-score fluctúa entre 0,61 y 0,76. En OCR, los valores de CER varían entre 0,08 y 0,27, con mejores resultados en 1080p a 30 FPS.

En términos generales, la reducción a 15 FPS afecta tanto la detección como el OCR, especialmente cuando los letreros aparecen durante pocos frames o cuando existen lluvia, neblina o desenfoque por movimiento. La resolución también influye, aunque el efecto observado en OCR sugiere que la disponibilidad temporal de frames nítidos es tan importante como la cantidad de píxeles. La configuración 1080p a 30 FPS presenta el mejor equilibrio general, con valores de OCR buenos o aceptables en los tres videos.

V-B. Evaluación end-to-end

La evaluación integral considera el flujo completo que recibe el usuario: detección del letrero, extracción de texto, clasificación semántica, evaluación de calidad informativa y georreferenciación. En la configuración original 1080p a 30 FPS, V1 contenía 23 letreros turísticos reales, de los cuales 21 fueron correctamente detectados; 11 superaron el filtro de confianza OCR y fueron evaluados y clasificados. En V2, 3 de 4 letreros turísticos fueron detectados y los 3 pasaron el filtro OCR. En V3, 18 de 19 letreros turísticos fueron detectados, pero solo 10 superaron el umbral OCR.

En conjunto, el pipeline logró evaluar y clasificar exitosamente 24 de 42 letreros turísticos correctamente detectados, lo que corresponde a una tasa end-to-end de 57,1 %. Este resultado muestra que la etapa de OCR actúa como el principal filtro del pipeline. Aunque el detector identifica la mayor parte de los letreros turísticos visibles, cerca de la mitad de ellos puede perderse antes de la clasificación final debido a baja nitidez, deterioro, ángulo de captura, reflejos o desenfoque por movimiento.

La Figura 3 ilustra un caso exitoso de procesamiento completo: se captura el video y la traza GPS, el modelo detecta el letrero, se sincronizan ambas fuentes, se extrae la ROI y se procesa, el OCR recupera texto con alta confianza, la taxonomía asigna una categoría turística y el resultado se visualiza sobre un mapa con coordenadas asociadas.

Tabla VI
RESUMEN DE RESULTADOS DE DETECCIÓN Y OCR POR CONFIGURACIÓN.

Video	Resolución	FPS	Precisión	Recall	F1-score	CER prom.	Interpretación prom. CER
V1	1080p	30	0,87	0,63	0,73	0,13	Aceptable
V1	1080p	15	0,85	0,60	0,70	0,23	Deficiente
V1	720p	30	0,91	0,60	0,72	0,16	Aceptable
V1	720p	15	0,88	0,52	0,65	0,22	Deficiente
V2	1080p	30	0,84	0,62	0,71	0,08	Bueno
V2	1080p	15	0,78	0,74	0,76	0,27	Deficiente
V2	720p	30	0,86	0,53	0,66	0,16	Aceptable
V2	720p	15	0,77	0,50	0,61	0,16	Aceptable
V3	1080p	30	0,85	0,63	0,72	0,10	Bueno
V3	1080p	15	0,81	0,67	0,73	0,20	Aceptable
V3	720p	30	0,82	0,55	0,66	0,24	Deficiente
V3	720p	15	0,89	0,59	0,72	0,21	Deficiente



Figura 3. Ejemplo de ejecución end-to-end de GEODETECTOR sobre un letrero turístico capturado en ruta.




Figura 4. Mapa interactivo con la distribución geográfica de las detecciones obtenidas en los tres videos de prueba.

V-C. Visualización georreferenciada

Los resultados consolidados fueron representados en un SIG. La Figura 4 muestra la distribución geográfica de las detecciones obtenidas en los tres videos. Cada punto representa un letrero detectado y georreferenciado; al seleccionarlo, el usuario puede revisar coordenadas, categoría, texto reconocido, confianza de detección, condiciones de captura y calidad informativa. Este componente permite transformar detecciones individuales en una herramienta de apoyo para inventarios territoriales.

VI. DISCUSIÓN

Los resultados evidencian que GEODETECTOR es viable para detectar y geolocalizar letreros turísticos en condiciones reales de captura vehicular. La Precisión promedio obtenida

en video se mantiene cercana al desempeño de validación del detector, lo que respalda la decisión de entrenar un modelo especializado en lugar de depender de clases generales de YOLO. Esta observación es consistente con trabajos que muestran degradación por cambio de dominio cuando el dataset de entrenamiento no representa el escenario de aplicación [15], [40].

La caída en Recall respecto al obtenido durante el entrenamiento era esperable, ya que la evaluación en video introduce factores ausentes en imágenes estáticas: movimiento del vehículo, tiempo limitado de aparición del letrero, vibración de cámara, lluvia, neblina y oclusión parcial. Estos efectos han sido reportados previamente en análisis de robustez de detectores bajo condiciones climáticas realistas [10]. En este sentido, el aporte del trabajo no está en obtener una detección perfecta, sino en cuantificar de manera transparente el desempeño de un pipeline completo bajo condiciones no controladas.

El módulo OCR constituye el principal cuello de botella. Aunque PaddleOCR permite leer texto en múltiples idiomas y escenas complejas, su desempeño depende fuertemente de la calidad de la ROI recibida. La tasa end-to-end de 57,1 % muestra que detectar el letrero no basta: también se requiere disponer de frames suficientemente nítidos para extraer texto útil. Las configuraciones de 1080p a 30 FPS ofrecen mejores condiciones para recuperar texto, mientras que 15 FPS reduce la probabilidad de seleccionar un frame legible.

La Figura 5 muestra ejemplos de limitaciones observadas. Algunos falsos positivos (FP) se producen por objetos rectangulares o planos, como laterales de camiones, banderas ondeando o estructuras viales. También se detectan señales de tránsito convencionales que comparten rasgos visuales con



Figura 5. Ejemplos de limitaciones: falsos positivos y detecciones sobre objetos visualmente similares a letreros.

letreros, pero que no pertenecen al dominio turístico. Estos casos sugieren que futuras versiones podrían incorporar una segunda etapa de filtrado visual, modelos multimodales o clasificadores específicos para distinguir señalética turística de otros objetos viales.

VII. CONCLUSIONES

Este artículo presentó GEODETECTOR, un pipeline híbrido para detección, reconocimiento de texto, clasificación semántica y georreferenciación de letreros turísticos capturados desde vehículos en movimiento. La propuesta integra un detector YOLO11m entrenado con un dataset propio de 2.000 imágenes, procesamiento de ROI, OCR, una taxonomía turística basada en palabras clave y sincronización GPS para visualización en mapa.

Los experimentos realizados sobre tres rutas reales de la Región de Los Lagos, evaluados en cuatro configuraciones combinando resoluciones de 720p y 1080p con tasas de captura de 15 FPS y 30 FPS, muestran que el detector alcanza Precisión entre 0,77 y 0,91, Recall entre 0,50 y 0,74 y F1-score entre 0,61 y 0,76. El OCR obtuvo valores de CER entre 0,08 y 0,27, confirmando que la lectura de texto en escenas naturales y en movimiento es la etapa más sensible del pipeline. En evaluación end-to-end, el pipeline completó automáticamente el flujo para el 57,1 % de los letreros turísticos correctamente detectados.

Con el fin de facilitar la revisión y reproducibilidad de este trabajo, el repositorio asociado al artículo, que incluye el código principal empleado en esta investigación y en cuyo archivo README se encuentran los enlaces a los videos utilizados para este artículo y a los videos de prueba empleados para ajustar el modelo, se encuentra disponible en el siguiente enlace:

<https://github.com/robleaustral/geodetector>

Como trabajo futuro se proyecta ampliar el dataset con nuevas regiones, evaluar técnicas de super-resolución [41] y corrección de desenfoque [42], desarrollar una aplicación móvil que capture video y GPS de manera integrada, y migrar el almacenamiento de resultados hacia una base de datos geoespacial. También resulta relevante explorar edge computing para aproximar el pipeline a una ejecución en tiempo real desde el vehículo.

AGRADECIMIENTOS

Esta investigación fue apoyada por el supercomputador Patagón de la Universidad Austral de Chile (FONDEQUIP EQM180042).

REFERENCIAS

- [1] T. Wang, H. Qu, C. Liu, T. Zheng, and Z. Lyu, "Lle-std: Traffic sign detection method based on low-light image enhancement and small target detection," *Mathematics*, vol. 12, no. 19, 2024. [Online]. Available: <https://www.mdpi.com/2227-7390/12/19/3125>
- [2] P. Martínez Otero, A. Tellaeché, and M. Hernández Melero, "Performance analysis of the yolo object detection algorithm in embedded systems: Generated code vs. native implementation," *Computation*, vol. 14, no. 3, p. 67, 2026.
- [3] V. K. Soni, V. Shukla, S. Tandan, A. Pimpalkar, N. K. Nema, and M. Naik, "Performance evaluation of efficient and accurate text detection and recognition in natural scenes images using east and ocr fusion," *International Journal of Advanced Computer Science & Applications*, vol. 16, no. 1, 2025.
- [4] X. Zhao, M. Xu, W. Silamu, and Y. Li, "Clip-llama: a new approach for scene text recognition with a pre-trained vision-language model and a pre-trained language model," *Sensors*, vol. 24, no. 22, p. 7371, 2024.
- [5] Z. Zhu, D. Liang, S. Zhang, X. Huang, B. Li, and S. Hu, "Traffic-sign detection and classification in the wild," in *The IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2016.
- [6] Y. Shi, "Traffic sign detection and recognition," Ph.D. dissertation, University of Canterbury, Christchurch, New Zealand, 2025, 2025.
- [7] B. Dwyer, "Using computer vision with drones for georeferencing," <https://blog.roboflow.com/georeferencing-drone-videos/>, September 2022, roboflow Blog, Accedido: 10 abril 2026.
- [8] S. Ren, K. He, R. Girshick, and J. Sun, "Faster r-cnn: Towards real-time object detection with region proposal networks," *Advances in neural information processing systems*, vol. 28, 2015.
- [9] E. Reswara, S. Suakanto, and S. A. Putra, "Comparison of object detection algorithm using yolo vs faster r-cnn: A systematic literature review," in *Proceedings of the 2023 6th International Conference on Big Data Technologies*, 2023, pp. 419–424.
- [10] S. Gholinavaz, N. Saeedi, and S. S. Ghahreveran, "Robustness analysis of yolo and faster r-cnn for object detection in realistic weather scenarios with noise augmentation," *Scientific Reports*, vol. 15, no. 1, p. 44888, 2025.
- [11] P. Kuneekar, K. Vayadande, O. Kulkarni, K. Ingale, R. Kadam, and S. Inamdar, "Ocr based cheque validation using image processing," in *2023 5th Biennial International Conference on Nascent Technologies in Engineering (ICNTE)*. IEEE, 2023, pp. 1–5.
- [12] M. F. Acevedo Cote and S. M. Morales Romero, "Implementación de ocr: reconocimiento óptico de caracteres para búsqueda de coincidencias en compras en líneas," 2023.
- [13] K. M. Mayor Arreaga, "Técnicas d'ocr en informes mèdics en països en vies de desenvolupament," 2023.
- [14] X. Luan, J. Zhang, M. Xu, W. Silamu, and Y. Li, "Lightweight scene text recognition based on transformer," *Sensors*, vol. 23, no. 9, p. 4490, 2023.
- [15] P. Oza, V. A. Sindagi, V. M. Patel *et al.*, "Unsupervised domain adaptation of object detectors: A survey," *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. 46, no. 6, pp. 4018–4040, 2023.
- [16] L. Torrey and J. Shavlik, "Transfer learning," in *Handbook of research on machine learning applications and trends: algorithms, methods, and techniques*. IGI Global Scientific Publishing, 2010, pp. 242–264.
- [17] Z. Situ, S. Teng, W. Feng, Q. Zhong, G. Chen, J. Su, and Q. Zhou, "A transfer learning-based yolo network for sewer defect detection in comparison to classic object detection methods," *Developments in the Built Environment*, vol. 15, p. 100191, 2023.
- [18] Human Signal, "Label Studio: Data labeling software," <https://labelstud.io/>, 2026, accedido: 14 abril 2026.
- [19] Python Software Foundation, "Python Programming Language," <https://www.python.org/>, 2026, accedido: 14 abril 2026.
- [20] The GIMP Development Team, "GIMP: Gnu image manipulation program," <https://www.gimp.org/>, 2026, accedido: 14 abril 2026.
- [21] F. Cordova, L. Veas-Castillo, and C. Lazo, "Roadsignvision: A dataset of informational and commercial road signs," 2025, disponible en: <https://dx.doi.org/10.21227/e1xe-pv82>.
- [22] A. Saakyan, "Custom training pipeline for object detection models," <https://medium.com/@reachraktim/letterboxing-in-yolov5-yolov7-yolov8-an-intuitive-explanation-with-python-code-88f7d4323d6c>, 2025, accedido: 14 abril 2026.
- [23] Ultralytics, "YOLO11: Modelos de detección de objetos," <https://docs.ultralytics.com/es/models/yolo11/>, 2026, accedido: 14 abril 2026.

- [24] Patagón Supercomputer, <https://patagon.uach.cl>, 2021, accedido: 14 abril 2026.
- [25] R. L. Kshetry, "Image preprocessing and modified adaptive thresholding for improving ocr," 2021. [Online]. Available: <https://arxiv.org/abs/2111.14075>
- [26] M. J. Swain and D. H. Ballard, "Color indexing," *International Journal of Computer Vision*, vol. 7, no. 1, pp. 11–32, 1991. [Online]. Available: <https://doi.org/10.1007/BF00130487>
- [27] P. Gil, F. Torres, and F. G. Ortiz, "Detección de objetos por segmentación multinivel combinada de espacios de color," *XXV Jornadas de Automática*, 2004.
- [28] C. Cui, T. Sun, S. Liang, T. Gao, Z. Zhang, J. Liu, X. Wang, C. Zhou, H. Liu, M. Lin, Y. Zhang, Y. Zhang, H. Zheng, J. Zhang, J. Zhang, Y. Liu, D. Yu, and Y. Ma, "Paddleocr-vl: Boosting multilingual document parsing via a 0.9b ultra-compact vision-language model," 2025. [Online]. Available: <https://arxiv.org/abs/2510.14528>
- [29] PaddleOCR, "Documentación de paddleocr," <https://www.paddleocr.ai/main/>, 2026, accedido: 16 abril 2026.
- [30] Servicio Nacional de Turismo (SERNATUR), "Resumen ejecutivo: Metodología para la definición de destinos turísticos," https://www.sernatur.cl/wp-content/uploads/2024/05/Resumen-Ejecutivo-Metodologi%CC%81a-para-definir-Destinos_2024.pdf, 2024, gobierno de Chile. Accedido: 28 abril 2026.
- [31] J. Ortega, F. Sánchez-Martínez, and M. Forcada, "Fuzzy-match repair using black-box machine translation systems: what can be expected?" 2016. [Online]. Available: <https://aclanthology.org/2016.amta-researchers.3/>
- [32] Geo-Tracker Team, "Geo-tracker: Gps tracking and trip recording application," <https://geo-tracker.org/en/>, 2026, accedido: 16 abril 2026.
- [33] L. Sautier, "pymediainfo: Python wrapper for mediainfo library," <https://pypi.org/project/pymediainfo/>, 2025, python package for extracting detailed metadata from multimedia files. Accedido: 16 abril 2026.
- [34] The pandas development team, "pandas: Python data analysis library," <https://pandas.pydata.org/>, 2025, high-performance data structures and data analysis tools for Python. Accedido: 16 abril 2026.
- [35] Open Source Vision Foundation, "OpenCV: Open Source Computer Vision Library," <https://opencv.org/>, 2000, accedido: 2 mayo 2026.
- [36] FFmpeg Developers, "Ffmpeg," <https://ffmpeg.org/>, 2026, accedido: 22 mayo 2026.
- [37] T. Krantz and A. Jonker, "What is ground truth in machine learning?" <https://www.ibm.com/think/topics/ground-truth>, IBM, 2025, accedido: 20 mayo 2026.
- [38] V. I. Levenshtein *et al.*, "Binary codes capable of correcting deletions, insertions, and reversals," in *Soviet physics doklady*, vol. 10, no. 8. Soviet Union, 1966, pp. 707–710.
- [39] Transkribus, "Character error rate and learning curve," <https://help.transkribus.org/character-error-rate-and-learning-curve>, 2025, accedido: 23 mayo 2026.
- [40] M. Paiano, S. Martina, C. Giannelli, and F. Caruso, "Transfer learning with generative models for object detection on limited datasets," *Machine Learning: Science and Technology*, vol. 5, no. 3, p. 035041, 2024.
- [41] Ultralytics, "What is super resolution? ai image enhancement," <https://www.ultralytics.com/glossary/super-resolution>, 2025, accedido: 5 junio 2026.
- [42] Y. Xiang, H. Zhou, C. Li, F. Sun, Z. Li, and Y. Xie, "Deep learning in motion deblurring: current status, benchmarks and future prospects," *The Visual Computer*, 2025.